Conceptos y aplicaciones en Big Data

Trabajo Práctico 2 – Modalidad de cursada presencial

Spark – Monitoreo de tráfico

Pautas generales

- La entrega consiste en la implementación de scritps de pyspark, resolviendo todas las consignas presentes en este enunciado.
- Los alumnos pueden conformar grupo de no más de dos integrantes y hacer una única entrega grupal.
- La entrega se realiza por la mensajería del curso en IDEAS.
- La fecha límite de entrega es el 15 de noviembre de 2026.

Enunciado

La ciudad de Zootopia almacena la geoposición de todos los vehículos que transitan durante el día.

El dataset está conformado por:

- ID_Vehiculo
- Latitud
- Longitud
- Timestamp
- Destino

Un viaje comienza en una determinada coordenada y finaliza en otra, la finalización está marcada con el lugar de destino. Durante el trayecto se van registrando las diferentes coordenadas por la cual transita el vehículo hasta llegar al destino.

Ejemplo:

ID	Lat	Lon	Timestamp	Destino
905	28	28	8079	
905	28	27	8088	
905	27	27	8097	
905	26	27	8106	
905	25	27	8115	
905	24	27	8124	Escuela

NOTA: asuma que la cantidad de vehículos, de viajes, de duración y de destinos es Big Data.

1) Implemente un script de pySpark que permita conocer cuántos viajes realizó cada vehículo. Recordar que un viaje es una serie de coordenadas que finalizan en un destino determinado.
   Ejemplo:

Vehículo	Viajes
511	4
697	11
151	1
653	3

2) Implemente un script de Spark que permita conocer cual es el top 3 de los "tipos" de destinos más visitados. NO interesa contar a los destinos "Otro".
   Ejemplo:

Tipo de destino	Cantidad de visitas
Supermercado	316
Museo	197
Escuela	193

3) Implemente un script de Spark que permita conocer la cantidad de vehículos (distintos) en movimiento por franja horaria. Un vehículo se considera en movimiento dentro de una franja horario si al menos registra N geolocalizaciones dentro de la propia franja. La duración de la franja horaria y el N son parámetros de la consulta.
   Ejemplo:

Franja horaria	Vehículos en movimiento
0 - 3000	843
3000 - 6000	673
6000 - 9000	449
9000 - 12000	248

4) Implemente un script de Spark que permita conocer la velocidad promedio de cada vehículo: el promedio de las velocidades de todos sus viajes.
La velocidad de un viaje se calcula como el tiempo del viaje (timestamp de fin – timestamp de inicio) dividido la cantidad de cuadras del viaje.
Ejemplo:

Vehículo	Velocidad promedio
511	23.6
697	11.5
151	101
653	32.4

A cada destino de un viaje se le asigna un ID único:

ID	Lat	Lon	Timestamp	Destino	ID_Viaje
905	54	41	5079	Museo	905_5079
905	5	2	6088	Cine	905_6088
478	35	91	7097	Banco	478_7097
478	58	15	9054	Colegio	478_9054
905	24	27	8124	Escuela	905_8124

Las geolocalizaciones que no tienen destino tendrán el mismo ID de viaje que el destino posterior más próximo:

ID	Lat	Lon	Timestamp	Destino	ID_Viaje
905	54	39	4987		905_5079
905	25	20	5741		905_6088
478	15	74	6812		478_7097
478	58	14	9028		478_9054
905	22	35	7902		905_8124

Para cada vehículo hay que conocer todos los ID de viajes y sus respectivos IDs. Luego para cada geolocalización hay que determinar que ID de viaje le corresponde (según el timestamp).